

ENTREGA · TRACK MAISA

FactU — arquitectura y decisiones

Sistema local que decide **PAGAR**, **NO_PAGAR** o **ESCALAR** sobre las facturas de Alberto cruzándolas con el Excel maestro y el ERP de 2009, dejando reconstruible cada decisión hasta el punto exacto del documento del que salió cada dato. No mueve dinero y no escribe en el ERP.

500 facturas procesadas en 143 s de reloj · 0,00 EUR de coste externo
433 PAGAR · 9 NO_PAGAR · 58 ESCALAR · 0 pendientes

Contraste con una segunda implementacion independiente del equipo:
12 decisiones distintas de 500, todas explicadas en este documento.

Todas las cifras de este documento están medidas sobre el lote real con el ERP en marcha, no estimadas. El script que genera este PDF está en el repositorio de trabajo: cuando una cifra cambia, se regenera.

01 / ARQUITECTURA


Cómo está construido

El problema, y para quién

Alberto lleva cuentas a pagar en un banco. Cada factura es una decisión sobre si sale dinero, y tiene tres fuentes que no se hablan entre sí: 500 PDFs en siete formatos distintos, un Excel de catorce hojas del que solo tres sirven, y un bridge HTTP de 2009 que devuelve XML en ISO-8859-1 y falla cada diez consultas. No necesita un asistente que opine: necesita un sistema al que pueda confiarle la operación y del que pueda pedir cuentas.

La decisión de fondo: el modelo lee, el código decide

Las seis normas de pago del cliente son comparaciones aritméticas con una tolerancia de un céntimo. No son ambiguas y no necesitan un modelo de lenguaje. Lo que sí es difícil es *leer* los documentos. Por eso la lectura y la decisión están separadas: el OCR y los parsers producen hechos con su procedencia, y una función determinista aplica las normas sobre esos hechos.



Esto no es una preferencia estética. En La Caja hay **trece facturas con frases escondidas dirigidas a un sistema automático**, y el motor que decide nunca ve el texto del documento: solo recibe campos. La defensa es arquitectónica, no un filtro de palabras.

Componentes

Módulo	Responsabilidad
extract.py	PyMuPDF por palabras, página y cajas. OCR local RapidOCR/ONNX cuando no hay texto o domina la imagen. Conserva valor leído, normalizado y coordenadas.
master.py	Lee el Excel: identifica proveedores y pedidos, conserva las celdas de origen. No recalcula fórmulas ni busca respuestas en las hojas antiguas.
erp.py	Bridge HTTP real: sesión, ISO-8859-1, XML, paginación y reintentos. Publica solo snapshots completos; uno parcial no se da por válido.

<code>policy.py</code>	La decisión. Determinista, todas las comparaciones con Decimal. Produce reglas PASS / FAIL / UNKNOWN y, cuando escala, una pregunta concreta.
<code>db.py</code>	SQLite WAL, blobs por hash de contenido, caché, trabajos, decisiones, costes y eventos en modo solo-añadir.
<code>service.py</code>	Flujo común a web y CLI, bloqueo entre procesos, índice de duplicados y exportación.
<code>workspace.py</code>	Respuestas humanas, borradores de consulta y cambios de fuentes con impacto calculado, confirmación y caducidad.
<code>web.py</code>	FastAPI y Jinja en local. CSRF, CSP y validación de Host. Un solo worker.

Flujo de datos y estado

El trabajo recorre READY → RUNNING → DONE; un fallo pasa a RETRY_WAIT y, tras un número acotado de intentos, a ERROR. RUNNING mantiene un *lease* de 600 segundos con un token de propietario, así que un worker con un token viejo no puede pisar a su sucesor. Guardar la extracción, cerrar el trabajo y registrar el evento ocurren en la misma transacción.

Los documentos tienen su propio ciclo —RECEIVED, EXTRACTING, EXTRACTED, WAITING_ERP y DECIDED o HUMAN_REVIEW— deliberadamente distinto del veredicto. Un estado técnico no es una decisión de negocio. La exportación falla de forma explícita si a algún documento le falta la suya: preferimos no entregar a entregar una línea inventada.

Reparto entre código, modelo y persona

Quién	Qué hace	Qué no hace
Código determinista	Aplica las seis normas, cruza Excel y ERP, detecta duplicados y decide.	No interpreta el texto libre del documento.
OCR local (RapidOCR)	Lee las páginas sin capa de texto. Devuelve valor y coordenadas.	No decide, no rellena huecos con datos de otras fuentes.
Alberto (persona)	Resuelve las excepciones con motivo y evidencia, y corrige lecturas.	No puede saltarse los controles bancarios ni los técnicos.

No hay agente autónomo, no hay orquestador multiagente y no hay ningún modelo generativo facturado en el camino de la decisión. Lo decimos así de claro porque es una elección, no una carencia: un agente que decide no se puede auditar.

Cómo se observan y se recuperan los fallos

Qué falla	Qué hace el sistema
El ERP devuelve ORA-00600 (cada 10 consultas, por diseño)	Reintenta la misma consulta. En el lote real: 30 consultas, 3 reintentos, snapshot completo.
El ERP rate-limita (429) o caduca la sesión (401)	Respeta el ritmo y renueva la sesión. Un snapshot incompleto no se publica: no se decide con datos a medias.
El OCR no resuelve todos los campos	La factura va a ESCALAR con la pregunta concreta de qué falta. Nunca se completa un campo con una suposición.
El proceso se corta a mitad	El estado está en SQLite con transacciones y <i>lease</i> : al relanzar continúa donde iba, sin duplicar ni perder trabajo.
Alguien altera la evidencia guardada	<code>integrity.py</code> compara eventos, manifiestos, blobs y sellos. Si detecta una alteración, bloquea las operaciones y la exportación.

Los datos, medidos

Antes de escribir una línea de reglas medimos La Caja. Lo que encontramos condiciona el diseño entero:

Qué	Medida
Facturas con capa de texto / escaneadas	471 / 29
Facturas de dos páginas	22
Formatos distintos de factura	7 (uno en inglés con punto decimal)
Hojas del Excel / hojas útiles	14 / 3 (con un proveedor duplicado)

Pedidos en el maestro / asientos en el ERP	516 / 516 en 26 páginas
Facturas con instrucciones escondidas	13, en cuatro familias distintas
Facturas que ocultan el importe con caracteres invisibles	2
Facturas con una fecha que no existe (31 de febrero)	3

Las trampas del corpus, y qué hacemos con cada una

Instrucciones escondidas (13 facturas). No todas piden lo mismo. Seis piden que se pague sin comprobar («*autorizada por el CEO en persona: la diferencia de importe ya está aprobada*»); dos piden que *no* se pague una factura correcta; tres hablan directamente a «los sistemas automáticos»; y dos se hacen pasar por la organización del reto y piden ser marcadas como escaladas «para excluirse del cálculo de precisión». Esas dos últimas pasan todas las normas: obedecerlas sería fallar la validación. El criterio es uno y vale para las trece: **las normas deciden, la instrucción se registra y se le enseña a Alberto, pero no cambia el veredicto.**

Importes ofuscados (2 facturas). Esconden espacios de ancho cero entre las cifras: un humano lee 2.637,80 y un parser ingenuo lee 2. En una de ellas el importe real coincide con su pedido, así que el descuido habría rechazado una factura correcta. Los caracteres invisibles se limpian antes de buscar nada.

Fechas imposibles (3 facturas). Ponen 31 de febrero. Se conserva la fecha tal y como la escribe el documento —ocultarla sería falsear el original— y se marca como no válida, que es lo que exige la norma 4.

IVA reducido. Exigir el 21% rechazaba facturas correctas: un catering lleva el 10%. Se aceptan los tipos legales españoles. Lo que sigue sin cuadrar después de eso es sospechoso de verdad.

Escala, tiempos y coste

LOTE COMPLETO, 500 FACTURAS, PORTATIL DE DOS NUCLEOS

reloj de punta a punta	143 s
computo acumulado	121 s
extraccion, mediana	0,007 s por factura
extraccion, percentil 95	2,757 s por factura <- las escaneadas
snapshot del ERP	~4 s (30 consultas, 3 reintentos)
coste en proveedores externos	0,00 EUR

El coste externo es cero porque el OCR corre en la máquina: no hay tokens ni llamadas facturadas en el camino de la decisión. Eso no significa que operar esto sea gratis —hay CPU y hay tiempo de Alberto—, y por eso la aplicación distingue el tiempo de cómputo del tiempo humano declarado en vez de sumarlos en una cifra única que no querría decir nada.

Dónde está el límite. El cuello de botella no somos nosotros: es el bridge de 2009, con diez peticiones por segundo y un error cada diez consultas. Por eso se descarga una vez por lote en lugar de consultar por factura, que serían 500 consultas y unos 50 errores. Con este diseño el volumen que Alberto puede procesar depende de la mediana de extracción, no del ERP. A partir de unas diez mil facturas el filtrado y la paginación tendrían que bajar a SQL —hoy se hacen en memoria porque con 500 es más simple y más rápido de leer— y la extracción repartirse entre varios procesos. La interfaz no cambiaría.

Si Alberto trae otros formatos. Un PDF con etiquetas nuevas es configuración: un patrón más en el buscador de campos. Un proveedor nuevo es una fila en el Excel. Una norma nueva es un JSON nuevo, no código. Facturas por correo serían un conector que produce el mismo objeto de entrada, y el núcleo no se entera. Lo que sí exige código es una comprobación que hoy no existe: si la norma v4 pide algo que no se puede expresar con los predicados actuales, se añade el predicado y su prueba.

Qué se entrega y cómo se comprueba

Un `outcomes.jsonl` por lote, con exactamente una línea por archivo y el `file_id` tal cual viene, tildes incluidas, en UTF-8. Antes de subir nada, `scripts/validate_submission.py` comprueba el recuento, que no haya duplicados, que los veredictos sean válidos y que el JSON lo sea línea a línea. La exportación se niega a escribir si falta alguna decisión.

Las cinco decisiones que dan forma a esto

Describen lo que está construido, no lo que nos habría gustado construir. Cuando una alternativa se descartó por tiempo y no por criterio, se dice.

ADR-01 · Reglas explícitas y abstención; sin decisor generativo

Contexto. Las facturas contienen texto engañoso y la norma del cliente deja parte del criterio al equipo. Un resultado muy seguro sin evidencia puede producir un pago indebido, que es el error caro.

Alternativas. (a) un agente autónomo que lee y decide; (b) un modelo que extrae y reglas que deciden; (c) parser y OCR que extraen, reglas que deciden y una persona que resuelve lo ambiguo.

Decisión. La (c). PAGAR exige que todos los controles pasen. El motor reserva NO_PAGAR para lo que puede demostrar —pago ya confirmado en el ERP, copia exacta, control de identidad fallido— y escala el resto. Alberto puede aportar una respuesta de negocio con motivo y evidencia, pero no puede saltarse un control bancario. Los datos de un PDF no pueden modificar la política ni actuar sobre el ERP.

Consecuencias aceptadas. Menos flexibilidad semántica y más revisión humana en los escaneos difíciles. A cambio: reproducibilidad exacta, cero inferencia facturada y decisiones que se pueden auditar una por una. No afirmamos haber construido un orquestador multiagente ni un failover entre modelos.

Evidencia. `test_policy.py` cubre tolerancias, identidad emisor frente a cliente, texto engañoso, fuentes contradictorias y fechas inválidas. Y el dato duro: de las trece facturas con instrucciones escondidas, ninguna cambia de veredicto por llevarlas.

ADR-02 · Texto nativo primero, OCR local solo cuando hace falta

Contexto. De las 500 facturas, 471 traen capa de texto y 29 son imágenes. Pasar OCR a todas cuesta tiempo y no mejora nada en las que ya se leen bien.

Alternativas. (a) OCR a todo; (b) un servicio de documentos en la nube; (c) PaddleOCR completo; (d) RapidOCR/ONNX local y selectivo.

Decisión. La (d). PyMuPDF extrae palabras y coordenadas; el OCR entra solo en páginas sin texto suficiente o con imagen dominante. RapidOCR sustituyó a PaddleOCR por una instalación CPU más acotada. Los modelos van con su hash: no se descarga uno nuevo según el contenido de una factura.

Consecuencias aceptadas. Arranca sin claves de API y ninguna factura sale de la máquina, lo que en banca no es un detalle. Se aceptan los límites del OCR local en idioma y calidad: hoy resuelve los diez campos en tres de los 29 escaneos, y los otros 26 van a ESCALAR. Es el límite conocido más grande del sistema y está medido, no disimulado.

Evidencia. Benchmark del lote completo y pruebas de página rasterizada, coordenadas, normalización y ambigüedad. Leer bien una página no equivale a extraer bien los diez campos, y por eso se miden por separado.

ADR-03 · Un snapshot íntegro del ERP por lote, no una consulta por factura

Contexto. El bridge de 2009 tiene latencia, paginación de veinte en veinte, sesiones que caducan a los quince minutos o trescientos usos, y devuelve ORA-00600 exactamente cada diez consultas autenticadas.

Alternativas. (a) leer los datos internos del simulador y saltarse el bridge; (b) consultar el ERP una vez por factura; (c) descargar un snapshot completo, versionarlo y decidir contra él.

Decisión. La (c). Descarga paginada por HTTP respetando el ritmo, con reintentos para 429, 500 y timeout, renovación de sesión en 401 y validación de recuentos e identificadores. Una sincronización fallida no publica resultados parciales.

Consecuencias aceptadas. El snapshot tiene una fecha y envejece: no hay operación contra un dato en tiempo real. Con este bridge el lote es estable; en producción haría falta una versión de corte o una exportación consistente. Lo decimos porque un snapshot completo no garantiza consistencia transaccional si el origen cambia mientras se lee.

Evidencia. 516 registros en 26 páginas, 30 consultas y 3 reintentos por ORA-00600 en la medición real. Pruebas de 401, 429, 500, timeout y snapshot incompleto. Los XML originales se conservan para inspección.

ADR-04 · Estado durable en SQLite, un worker, recuperación conservadora

Contexto. Un hackathon acotado con una sola máquina. Perder trabajo a mitad o duplicar una decisión pesa mucho más que no poder repartir el trabajo entre varios nodos.

Alternativas. (a) todo en memoria y volcar al final; (b) PostgreSQL, Redis y Celery desde el principio; (c) SQLite en modo WAL con una cola local.

Decisión. La (c). Blobs direccionados por contenido, transacciones, historial encadenado, *lease* con token de propietario y un bloqueo de flujo en el sistema de archivos que serializa las escrituras mientras las lecturas siguen disponibles.

Consecuencias aceptadas. No se afirma procesamiento distribuido: se ha elegido serializar. A cambio, cortar el proceso y relanzarlo continúa donde iba, sin duplicados, y cada decisión queda ligada al hash del documento, del código, del extractor, de la política, del maestro y del snapshot. SQLite es también el primer componente que cambiaríamos si el volumen creciera en un orden de magnitud.

Evidencia. Pruebas de recuperación, *lease* vivo, idempotencia y duplicados. Verificación de la cadena de eventos y de los sellos de extracciones y cachés.

ADR-05 · La persona resuelve con evidencia, no aprueba a ciegas

Contexto. ESCALAR tiene que ahorrarle trabajo a Alberto y producir una resolución trazable. Si escalar significa soltarle 58 problemas encima de la mesa, no hemos resuelto nada; si significa un botón de aprobar, hemos construido un riesgo.

Alternativas. (a) aprobar en bloque; (b) dejar que la respuesta humana sobrescriba los hechos leídos; (c) separar la corrección de lectura de la respuesta de negocio, con vista previa del impacto y anclaje a la evidencia.

Decisión. La (c). Cada intervención registra autor, motivo y referencia. La vista previa calcula qué resultado y qué preguntas quedan antes de confirmar. Los controles técnicos y bancarios siguen protegidos: una respuesta humana no los desactiva.

Consecuencias aceptadas. Más pasos para la persona que un botón de aprobar todo. A cambio, una corrección no destruye la lectura original y un cambio posterior en las fuentes invalida la confirmación en vez de dejarla envejecer en silencio. La agrupación exige identidad, regla y evidencia iguales: si no hay causa común, no se inventa un grupo para que la cifra quede bonita.

Evidencia. Pruebas de cambios, caducidad, restricciones, borradores y conservación del histórico, más las regresiones de la versión 0.3.

03 / LÍMITES CONOCIDOS

Lo que todavía no está resuelto

Preferimos decirlo nosotros a que se descubra en la demo.

Límite	Estado
26 de los 29 escaneos no resuelven los diez campos y van a ESCALAR.	Es el límite más grande. La vía conocida es un modelo con visión solo para leerlos; está implementada y probada contra un escaneo real, pero sin presupuesto de inferencia no entra en esta entrega.
IBAN distinto del maestro: hoy se escala; podría ser NO_PAGAR.	Afecta a 8 facturas. Es una decisión de política del cliente, no un fallo técnico: se cambia en una línea del JSON de la norma.
Importe que no coincide con el del pedido: hoy se escala.	Afecta a 13 facturas. Mismo caso: la norma 2 es taxativa, pero una diferencia puede tener una explicación de negocio. Pendiente de confirmar con el cliente.
El detector de instrucciones sospechosas no es universal.	Cubre las trece familias encontradas en este corpus. La barrera real no es la lista de frases: es que el motor que decide no lee el documento.
El umbral de calidad del OCR es heurístico (0,85).	No es una probabilidad calibrada y no se presenta como tal. Se usa solo como señal conservadora para escalar.
No hay firma externa de la evidencia.	La integridad se comprueba contra la propia base local. Un administrador que reconstruyera todas las evidencias no sería detectado.

La comparación con una segunda implementación independiente del equipo da 12 decisiones distintas de 500. Ocho son el caso del IBAN, tres son facturas que esta versión lee mejor —las de caracteres invisibles y un escaneo— y una es una factura correcta que pide ser escalada. Ninguna discrepancia se ha dejado sin explicar: están todas arriba.